

**Национальный исследовательский университет
«Высшая школа экономики»**

Факультет экономических наук
Образовательная программа «Экономика и анализ данных»

КУРСОВОЙ ПРОЕКТ

**Построение рекомендательных систем
"инвестор-актив" на основе матричных разложений и
машинного обучения**

Выполнил:

Студент 2 курса, группы 243
Докучаев Алексей Евгеньевич

Научные руководители:

Широков Дмитрий Сергеевич
Филимошина Екатерина Романовна

Москва, 2026

Содержание

Введение	3
1 Обзор литературы	6
1.1 Основные парадигмы рекомендательных систем	6
1.2 Матричная факторизация и методы ранжирования	7
1.3 Нейросетевые расширения матричной факторизации	9
1.4 Рекомендательные системы в финансовой сфере	9
1.5 Объяснимость рекомендаций	10
1.6 Исследовательский гэп и выбор методов	11
2 Основные определения и обозначения	14
2.1 Множества и индексы	14
2.2 Транзакции и матрица взаимодействий	14
2.3 Обучающая, валидационная и тестовая выборки	14
2.4 Положительные и отрицательные примеры	15
2.5 Признаки пользователей и активов	15
2.6 Скоринг и Тор-К рекомендации	16
2.7 Рассматриваемые модели	17
2.8 Латентные представления	17
2.9 Гибридная модель	18
2.10 Доходность и ROI	18
2.11 Метрики качества рекомендаций	18
2.12 Основные сокращения	19
3 Теоретическая часть (методы рекомендательных систем)	20
3.1 Popularity	20
3.2 User-based kNN	20
3.3 Item-based kNN	20
3.4 SVD	21
3.5 SVD++	21
3.6 NMF	22
3.7 WMF-ALS	22
3.8 BPR	23
3.9 NCF	23
3.10 Content-aware LGBM	24
3.11 Hybrid Rank Fusion	24
4 Практическая часть	26
4.1 Описание набора данных FAR-Trans	26
4.2 Предобработка данных и формирование матрицы взаимодействий	26

4.3	Разведочный анализ данных	27
4.4	Разбиение данных по времени	29
4.5	Формирование признаков пользователей и активов	30
4.6	Экспериментальная методология	31
4.7	Результаты экспериментов	33
4.8	Анализ результатов	35
4.9	Объяснение рекомендаций	36
4.10	Ограничения практической реализации	37
	Заключение	39
	Список литературы	45
	Описание применения генеративной модели	47

Введение

Актуальность темы.

За последние несколько лет на российском фондовом рынке заметно выросло число частных инвесторов и увеличился приток капитала. По данным Банка России, только в I квартале 2026 года физические лица внесли на брокерские счета около 910 млрд рублей, что стало максимальным квартальным показателем за весь период наблюдений с 2021 года [18]. Одновременно увеличивается и объем средств, находящихся на брокерском обслуживании, а также число доступных инвестиционных инструментов. Например, объем размещенных цифровых финансовых активов в 2025 году достиг 1,65 трлн рублей, почти втрое превысив показатель предыдущего года [20]. Рост интереса к инвестициям во многом связывают со снижением процентных ставок и постепенным смягчением денежно-кредитной политики, из-за чего часть капитала начинает перетекать с депозитов на фондовый рынок [18].

Вместе с ростом числа инвесторов растет и сложность принятия инвестиционных решений. Современный инвестор вынужден выбирать среди сотен акций, облигаций, биржевых фондов и других финансовых инструментов, отличающихся по уровню риска, доходности и ликвидности.

Для многих пользователей самостоятельный анализ такого объема информации оказывается затруднительным, особенно при отсутствии профессиональной подготовки. В результате возрастает спрос на инструменты, позволяющие помочь пользователю принять решение, способные формировать персонализированные рекомендации и помогать инвестору находить подходящие активы. На практике к подобным системам интерес проявляют брокерские компании, инвестиционные платформы, управляющие компании и финтех-сервисы. Использование рекомендательных алгоритмов позволяет персонализировать взаимодействие с клиентами, повышать вовлеченность пользователей и улучшать качество инвестиционных сервисов. Кроме того, такие модели могут использоваться для анализа инвестиционного поведения клиентов и поиска закономерностей в структуре их портфелей.

Классическим подходом к задаче выбора финансовых активов является теория портфеля Марковица [9]. Несмотря на ее фундаментальное значение для финансовой теории, этот метод предполагает наличие полной информации о рисках и доходностях активов, при этом практически не учитывает индивидуальные особенности поведения инвесторов. Но на практике инвесторы часто принимают решения под влиянием собственных предпочтений, опыта и ограниченной информации, из-за чего реальные портфели могут существенно отличаться от теоретически оптимальных.

Рекомендательные системы - это один из способов учитывать предпочтения инвесторов. Они используют информацию о действиях пользователей и позволяют находить неочевидные закономерности в инвестиционном поведении [7, 4]. Но применять рекомендательные системы в финансовой сфере достаточно трудно - сложности возникают и с доступностью данных, и с необходимостью постоянно учитывать изменяющиеся

показатели активов.

После публикации датасета Far-trans, который содержит анонимизированные данные о транзакциях частных инвесторов за период с 2018 по 2022 год [13]. Эти данные сделали возможным провести воспроизводимое сравнение различных алгоритмов на одной выборке. Результаты исследования показали, что методами, которые уже существуют, можно по-разному решать задачу рекомендаций финансовых активов. С одной стороны, алгоритмы, ориентированные на историю транзакций, лучше предсказывают будущие действия инвесторов, однако часто рекомендуют менее доходные активы. С другой стороны, модели, ориентированные на доходность, хуже учитывают индивидуальные предпочтения пользователей. В таком случае появляется запрос на построение гибридной системы, способной одновременно учитывать предпочтения инвесторов и характеристики финансовых активов. Этому и посвящена данная работа.

Цель исследования.

Целью настоящей работы является сравнительный анализ методов рекомендательных систем для финансовых активов на данных о транзакциях инвесторов за период 2018-2022 годов, а также разработка гибридной модели, объединяющей информацию об историческом поведении инвесторов и характеристиках финансовых активов, и оценка качества получаемых рекомендаций.

Задачи исследования.

Для достижения поставленной цели в работе решаются следующие задачи:

1. Провести обзор литературы по рекомендательным системам и их применению в финансовой сфере и выделить основные направления развития существующих подходов.
2. Подготовить рабочий датасет на основе данных о транзакциях инвесторов за период 2018-2022 год, сформировать матрицу взаимодействий инвестор-актив и набор признаков финансовых инструментов.
3. Реализовать и обучить базовые модели рекомендаций, включая коллаборативную фильтрацию, методы матричной факторизации, модели ранжирования и нейросетевые подходы.
4. Провести сравнительную оценку качества реализованных моделей с использованием метрик Precision@k, Recall@k и nDCG@k.
5. Разработать гибридную рекомендательную модель, объединяющую информацию об историческом поведении инвесторов и характеристиках финансовых активов.
6. Предложить подход к объяснению получаемых рекомендаций для различных типов моделей.
7. Сравнить результаты гибридной модели с базовыми алгоритмами и проанализировать полученные результаты.

Объект и предмет исследования.

- **Объект:** поведение розничных инвесторов на рынке финансовых активов.
- **Предмет:** методы построения персонализированных рекомендаций финансовых активов на основе коллаборативной фильтрации, матричных разложений, моделей ранжирования, нейросетевых моделей и их гибридных комбинаций.

Методы исследования.

В работе используются методы описательной статистики и визуализации данных для анализа набора транзакций инвесторов. В качестве рекомендательных алгоритмов рассматриваются методы коллаборативной фильтрации (user-based и item-based), модели матричной факторизации (SVD, SVD++, NMF, WMF), модель персонализированного ранжирования BPR, нейросетевая модель NCF, а также контентный подход на основе характеристик финансовых активов. Для построения итоговой рекомендательной системы исследуется гибридная модель, объединяющая информацию о поведении инвесторов и свойствах активов. Оценка качества рекомендаций проводится на временном разделении данных с использованием метрик Precision@k, Recall@k и nDCG@k.

Структура работы.

Работа состоит из введения, четырех разделов, заключения, списка литературы и приложений. В первом разделе представлен обзор литературы по рекомендательным системам и их применению в финансовой сфере. Во втором разделе вводятся основные определения и обозначения. Третий раздел посвящен теоретическому описанию рассматриваемых методов. В четвертом разделе рассматривается практическая реализация и приводятся результаты экспериментов на данных о транзакциях инвесторов. В заключении формулируются основные выводы, ограничения работы и направления дальнейших исследований.

1 Обзор литературы

В данном разделе рассматриваются исследования, которые помогли сформировать теоретическую основу этой работы. Сначала анализируются базовые подходы к построению рекомендательных систем - коллаборативная фильтрация, контентные методы и гибридные модели. Далее разбираются методы матричных разложений, их нейросетевые расширения. После этого рассматриваются рекомендательные системы именно в финансовой сфере. Отдельный подраздел посвящен объяснимости рекомендаций. Завершает раздел вывод по всем изученным источникам, где описаны ограничения работ, на основе которых были выбраны методы из практической части.

1.1 Основные парадигмы рекомендательных систем

Большинство алгоритмов, которые используются в современных рекомендательных системах, можно отнести к трем основным направлениям - коллаборативная фильтрация, контентные методы и гибридные модели. Эти направления отличаются источниками используемой информации и логикой формирования рекомендаций.

Коллаборативная фильтрация строится на предположении, что пользователи со схожим поведением в прошлом будут демонстрировать схожие предпочтения и в будущем. Такие методы используют историю взаимодействий пользователя с объектами. Такой подход стал основой для многих известных рекомендательных систем. Одной из первых статей, где идея коллаборативной фильтрации была реализована на практике, является работа о системе GroupLens [12]. Авторы предложили использовать матрицу пользовательских оценок для вычисления попарного сходства пользователей и формирования рекомендаций на основе мнений ближайших соседей. Позднее этот подход получил название user-based collaborative filtering. Преимуществом такого подхода является понятная логика работы: рекомендацию всегда можно связать с поведением похожих пользователей. Но у метода есть и проблема с масштабированием - по мере роста числа пользователей вычисление попарных сходств становится все более затратным.

Проблема масштабируемости привела к появлению альтернативного подхода - item-based collaborative filtering. В работе Sarwar и соавторов [14] вместо поиска похожих пользователей предлагается искать похожие объекты. На практике сходство между объектами обычно изменяется медленнее, чем предпочтения пользователей, поэтому такие модели проще применять в крупных системах. Кроме того, матрицу сходств между объектами можно вычислить заранее, что существенно ускоряет процесс генерации рекомендаций.

Контентные рекомендательные системы основаны не на истории поведения пользователей, а на характеристиках самих объектов. Они анализируют признаки объектов, с которыми пользователь уже взаимодействовал, и пытаются найти похожие варианты. Подробный обзор таких методов приведен в работе Pazzani и Billsus [10]. Главным преимуществом контентного подхода является его независимость от действий других

пользователей. Это особенно полезно при работе с новыми объектами. Однако качество рекомендаций в значительной степени зависит от того, насколько полно и корректно описаны признаки объектов.

У рассмотренных методов, как было частично уже упомянуто, есть ограничения - коллаборативная фильтрация плохо справляется с новыми пользователями и объектами, а контентные методы часто оказываются узконаправленными и рекомендуют только похожие объекты. По этой причине стоит обратить внимание на гибридные модели. Одной из наиболее изветных работ в этом направлении является исследование Burke [2]. Автор предложил классификацию гибридных систем и показал несколько способов объединения различных моделей. Выделяются взвешивание прогнозов нескольких алгоритмов, каскадные схемы отбора рекомендаций и использование результатов одной модели в качестве входных данных для другой. Выбор способа зависит от особенностей данных и задачи.

Для финансовых рекомендаций гибридные подходы представляют особый интерес, поскольку при формировании рекомендаций необходимо учитывать сразу несколько факторов: историческое поведение инвестора, характеристики финансовых активов, отношение пользователя к риску, а также рыночную ситуацию.

1.2 Матричная факторизация и методы ранжирования

Перед рассмотрением более сложных моделей стоит упомянуть рекомендации по популярности (Popularity). Пользователям предлагаются активы, которые наиболее часто встречаются в истории взаимодействий. Несмотря на простоту и отсутствие персонализации, подобная модель часто используется в качестве базовой линии сравнения. В частности, она входит в набор алгоритмов, рассмотренных авторами FAR-Trans при построении бенчмарка для финансовых рекомендательных систем [13].

Более сложные модели стремятся учитывать индивидуальные предпочтения пользователей и скрытую структуру взаимодействий. Одним из наиболее популярных подходов к решению этой задачи является матричная факторизация. Ее основная идея заключается в том, чтобы представить пользователей и объекты в общем латентном пространстве и описывать взаимодействия между ними через скрытые факторы. Пусть матрица взаимодействий пользователей и объектов имеет вид $R \in \mathbb{R}^{|U| \times |I|}$. Тогда каждому пользователю и каждому объекту сопоставляются латентные векторы меньшей размерности, а предсказание взаимодействия определяется их скалярным произведением:

$$\hat{r}_{ui} = q_i^\top p_u.$$

С помощью такого метода можно выявлять скрытые закономерности в поведении пользователей даже при высокой разреженности данных. Одно из наиболее известных описаний матричной факторизации представлено в работе Koren и соавторов [7], посвященной результатам соревнования Netflix Prize. Авторы показали, что использование

латентных факторов может значительно улучшить качество рекомендаций в сравнении с методами коллаборативной фильтрации. Но есть проблема - классическая матричная факторизация предполагает наличие явных оценок пользователей. Но для рекомендации финансовых активов таких данных нет в общем доступе: обычно есть лишь факт покупки актива. Для подобных случаев Ну и соавторы [5] предложили модель Weighted Matrix Factorization (WMF), в которой каждому взаимодействию сопоставляется уровень уверенности. Алгоритм из этой статьи позволяет использовать неявную обратную связь и учитывать как наблюдаемые взаимодействия, так и отсутствие взаимодействий.

Далее рассмотрим модель SVD++ [6]. Ее основная идея заключается в использовании неявной обратной связи при построении представления пользователя. Помимо собственного латентного вектора пользователя учитываются все объекты, с которыми он ранее взаимодействовал:

$$\hat{r}_{ui} = \mu + b_i + b_u + q_i^\top \left(p_u + |N(u)|^{-1/2} \sum_{j \in N(u)} y_j \right).$$

Поэтому модель способна использовать дополнительную информацию о поведении пользователя и превосходить базовую матричную факторизацию по качеству рекомендаций.

Можно и не только предсказывать оценки, но и использовать ранжирование результатов. На практике пользователю требуется не численное значение предпочтения, а упорядоченный список объектов. Одним из наиболее известных методов является Bayesian Personalized Ranking (BPR), предложенный Rendle и соавторами [11]. Вместо предсказания отдельных оценок модель оптимизирует вероятность того, что пользователь предпочтет объект с которым взаимодействовал ранее, объекту с которым взаимодействий не было:

$$\sum_{(u,i,j)} \ln \sigma(\hat{r}_{ui} - \hat{r}_{uj}) - \lambda \|\Theta\|^2 \rightarrow \max.$$

Так можно сразу ориентироваться на качество ранжирования, а еще этот метод хорошо подходит для решения задачи формирования Top k рекомендаций.

Стоит так же рассмотреть и неотрицательную матричную факторизацию (NMF), предложенную Lee и Seung [8]. Главное отличие здесь в том, что для метода появляется неотрицательность для обеих матриц факторов:

$$Q \geq 0, \quad P \geq 0.$$

Результаты такой модели проще интерпретировать. Скрытые факторы имеют более понятную структуру и позволяют легче анализировать полученные результаты.

В практической части работы рассмотрим методы SVD, SVD++, NMF, WMF и BPR и сравним их эффективность в задаче рекомендации финансовых активов.

1.3 Нейросетевые расширения матричной факторизации

Обычно матричная факторизация предполагает, что взаимодействие пользователя и объекта описывается скалярным произведением их латентных векторов. Это хорошо работает на практике, но моделирование ограничено относительно простыми зависимостями между пользователями и объектами. Развитие методов машинного обучения привело к появлению нейросетевых рекомендательных систем. Рассмотрим статью Хе и соавторов [4], в которой была предложена модель Neural Collaborative Filtering (NCF). Авторы заменили фиксированное скалярное произведение обучаемой нейронной сетью:

$$\hat{r}_{ui} = f(p_u, q_i \mid \Theta),$$

где p_u и q_i представляют латентные векторы пользователя и объекта, а f задается параметрами нейронной сети Θ . Главная идея NCF заключается в том, что нейронная сеть способна выявлять более сложные и нелинейные зависимости между пользователями и объектами, чем классическая матричная факторизация. В той же статье также была предложена архитектура NeuMF, объединяющая преимущества матричной факторизации и многослойного перцептрона в рамках одной модели.

Другой пример реализации это модель Deep Matrix Factorization (DMF), предложенная Хуе и соавторами [15]. Здесь нейросети используются для построения скрытых представлений пользователей и объектов из матрицы взаимодействий.

Ещё есть направление исследований, связанное с построением рекомендательных систем на основе обучения с подкреплением. Обзор таких методов представлен в работе Afsar и соавторов [1]. В подобных моделях процесс рекомендации рассматривается как последовательность действий, а алгоритм стремится максимизировать долгосрочное вознаграждение пользователя. Однако для применения таких методов обычно требуется либо возможность взаимодействия с пользователями в реальном времени, либо симуляции для моделирования взаимодействия. В моей работе не рассматриваются методы обучения с подкреплением поскольку датасет содержит только исторические транзакции и не предоставляет информации о последовательной реакции пользователей на рекомендации, а построение симуляции для моделирования взаимодействия - это отдельная исследовательская задача.

Из нейросетевых моделей в практической части реализуется NCF. Это один из наиболее распространенных нейросетевых методов рекомендаций и он позволяет сравнить качество нелинейных моделей с линейными.

1.4 Рекомендательные системы в финансовой сфере

Рекомендательные системы для финансовых активов отличаются от классических рекомендательных систем из-за специфики объектов рекомендаций. Если характеристики например фильмов и товаров почти не меняются со временем, то доходность и риск финансовых активов постоянно изменяются в зависимости от рыночной ситу-

ации. Базовым подходом к задаче выбора финансовых активов является теория портфеля Марковица [9]. Инвестор формирует портфель, стараясь достичь компромисса между ожидаемой доходностью и риском. Ограничение этой модели в том, что она не использует историю конкретного инвестора и не персонализирует рекомендации.

Обзор применения рекомендательных систем в финансах представлен в работе Zibriczky [17]. Автор рассматривает использование рекомендательных алгоритмов в банковской сфере, страховании, управлении активами и инвестиционных сервисах. Одной из основных проблем направления называется ограниченная доступность данных о действиях пользователей. По этой причине многие исследования выполнялись на небольших выборках, анкетных данных или синтетических наборах данных. Эта проблема сохраняется и по сей день, поскольку данные считаются персональными и их не могут выкладывать публично по юридическим причинам.

Адаптацией рекомендательных систем к финансовой области занимались и Chung с соавторами [3]. Авторы отмечают, что стандартная коллаборативная фильтрация может рекомендовать пользователю активы, похожие на уже имеющиеся в его портфеле, что приводит к снижению диверсификации. Для решения этой проблемы предлагается учитывать показатели риска и доходности непосредственно при обучении модели рекомендаций.

Существенный вклад в развитие направления внесла работа Sanz-Cruzado и соавторов [13], в которой был представлен открытый датасет FAR-Trans. Набор данных содержит информацию о транзакциях почти 29 тысяч инвесторов за период с 2018 по 2022 год, а также характеристики активов и данные о ценовой динамике. Появление такого датасета позволило проводить воспроизводимые исследования и сравнивать различные методы на единой выборке. Так же авторы исследовали разные алгоритмы, включая графовые нейронные сети и гибридные модели. Результаты показали, что методы, использующие историю транзакций, лучше предсказывают будущие действия инвесторов, но часто рекомендуют менее доходные активы, а модели, ориентированные на рыночные показатели и доходность хуже учитывают индивидуальные предпочтения пользователей.

В итоге в существующей литературе сохраняется открытый вопрос о том, каким образом объединять информацию о предпочтениях инвесторов и финансовых характеристиках активов. Простое объединение нескольких моделей не гарантирует улучшения качества рекомендаций, так как разные алгоритмы могут использовать противоречивую информацию. Поэтому поиск оптимальной гибридной модели остается актуальным.

1.5 Объяснимость рекомендаций

Кроме качества рекомендаций важным требованием к рекомендательной системе является возможность объяснить пользователю причины появления рекомендации. Для финансовой сферы этот вопрос имеет весомое значение, так как есть вероятность столкнуться с финансовыми потерями. Пользователь должен понимать какие факторы

повлияли на выбор актива и почему алгоритм считает его хорошим вариантом. Подходы к объяснимости рекомендательных систем представлены в работе Zhang и Chen [16]. Авторы выделили несколько основных источников объяснений: похожие пользователи, похожие объекты, признаки самих объектов, а так же внутренние представления модели. В зависимости от используемого алгоритма объяснение может создаваться сразу в процессе работы модели либо строиться после получения рекомендации.

В рамках моей работы объяснимость рекомендательной системы так же рассматривается в зависимости от алгоритма. Для методов ближайших соседей объяснение будет исходить из наиболее похожих пользователей или активов, повлиявших на рекомендацию. Для контентного подхода объяснение можно связать с характеристиками актива - к примеру экономический сектор, тип инструмента или уровень риска. Для моделей матричной факторизации или нейросетевых методов такой очевидной интерпретации обычно нет, поэтому объяснение будет строиться на основе признаков актива и его сходства с тем, что было куплено ранее.

1.6 Исследовательский гэп и выбор методов

Проведенный обзор литературы показывает, что для задачи рекомендаций финансовых активов существует большое количество подходов, начиная от классической коллаборативной фильтрации и методов матричной факторизации и заканчивая современными нейросетевыми моделями. При этом ни один из рассмотренных подходов нельзя назвать универсальным. Методы коллаборативной фильтрации хорошо используют информацию о прошлых действиях пользователей, однако не учитывают финансовые характеристики активов. Модели матричной факторизации позволяют выявлять скрытые закономерности в поведении инвесторов, но также ориентируются преимущественно на исторические взаимодействия. Нейросетевые методы способны моделировать более сложные зависимости, однако требуют большего объема данных и не всегда обеспечивают устойчивый прирост качества на разреженных выборках.

Исследовательский гэп заключается в сложности объединения различных источников информации в единую модель. Простое объединение нескольких алгоритмов не гарантирует улучшения качества рекомендаций, так как разные модели могут использовать противоречивую информацию и оптимизировать различные показатели. В качестве базовых моделей используются Popularity, User-based kNN и Item-based kNN. Методы матричной факторизации представлены моделями SVD, SVD++, NMF и WMF. Для оптимизации ранжирования дополнительно рассматривается модель BPR. Из нейросетевых методов реализуется NCF. Помимо этого исследуется контентный метод на основе характеристик финансовых активов.

Финальный этап работы - построение гибридной модели, объединяющей информацию о поведении инвесторов и свойствах активов. Основная гипотеза исследования состоит в том, что такая комбинация позволит получить более качественные рекомендации по сравнению с использованием отдельных моделей.

Таблица 1: Сводная таблица рассмотренных исследований

Автор(ы), год	Цель / гипотеза	Данные и методы	Ключевые результаты
Markowitz (1952) [9]	Формализовать задачу выбора портфеля активов	Вероятностная модель доходностей; портфельная оптимизация	Введены понятия эффективной границы и компромисса риск-доходность
Resnick и соавторы (1994) [12]	Построить систему фильтрации новостей на основе мнений пользователей	Оценки пользователей; user-based collaborative filtering	Показана практическая применимость коллаборативной фильтрации
Lee, Seung (1999) [8]	Получить интерпретируемое разложение данных	Матричная факторизация с ограничением неотрицательности	Предложена NMF, удобная для анализа скрытых компонент
Sarwar и соавторы (2001) [14]	Снизить вычислительную сложность коллаборативной фильтрации	MovieLens; item-based collaborative filtering	Предложен item-based подход с предвычисляемыми сходствами объектов
Burke (2002) [2]	Систематизировать способы объединения рекомендательных моделей	Обзор гибридных рекомендательных систем	Предложена классификация гибридных подходов
Pazzani, Billsus (2007) [10]	Описать методы рекомендаций на основе признаков объектов	Обзор контентных рекомендательных систем	Систематизированы преимущества и ограничения контентного подхода
Koren (2008) [6]	Расширить матричную факторизацию за счет неявной обратной связи	Netflix Prize; модель SVD++	Показано, что учет неявных взаимодействий улучшает качество рекомендаций
Hu и соавторы (2008) [5]	Адаптировать матричную факторизацию под неявную обратную связь	Implicit feedback; модель WMF	Введена модель с весами уверенности для наблюдаемых и ненаблюдаемых взаимодействий
Koren и соавторы (2009) [7]	Обобщить методы матричной факторизации	Netflix Prize; latent factor models	Описана стандартная схема матричной факторизации с bias-компонентами
Rendle и соавторы (2009) [11]	Оптимизировать персонализированное ранжирование	Implicit feedback; BPR	Предложен pairwise-критерий для задачи ранжирования
Zibriczky (2016) [17]	Обобщить применение рекомендательных систем в финансах	Обзор финансовых рекомендательных систем	Выделены проблемы доступности данных, приватности и специфики финансового домена
He и соавторы (2017) [4]	Расширить матричную факторизацию с помощью нейронных сетей	MovieLens, Pinterest; NCF и NeuMF	Показано преимущество нелинейного моделирования взаимодействий пользователей и объектов

Продолжение на следующей странице

Автор(ы), год	Цель / гипотеза	Данные и методы	Ключевые результаты
Хуе и соавторы (2017) [15]	Построить глубокую матричную факторизацию для рекомендаций	MovieLens, Amazon; DMF	Предложен способ формирования латентных представлений через нейронные сети
Zhang, Chen (2020) [16]	Систематизировать подходы к объяснимости рекомендаций	Обзор explainable recommendation	Выделены основные типы объяснений и способы их построения
Afsar и соавторы (2022) [1]	Систематизировать методы RL в рекомендательных системах	Обзор reinforcement learning recommender systems	Показаны перспективы RL для последовательных сценариев рекомендаций
Sanz-Cruzado и соавторы (2024) [13]	Предложить открытый датасет для финансовых рекомендаций и сравнить существующие методы	FAR-Trans; Popularity, kNN, MF, GNN и гибридные модели	Показано отсутствие универсально лучшего алгоритма и компромисс между качеством рекомендаций и доходностью активов
Chung и соавторы (2025) [3]	Интегрировать коллаборативную фильтрацию и портфельную теорию	Финансовые данные; MVECF	Показано, что учет риска и доходности может улучшать финансовую эффективность рекомендаций

2 Основные определения и обозначения

В этом разделе вводятся обозначения, которые используются далее при постановке задачи, описании моделей и оценке качества рекомендаций.

2.1 Множества и индексы

Пусть

$$\mathcal{U} = \{u_1, \dots, u_n\}$$

- множество инвесторов, а

$$\mathcal{I} = \{i_1, \dots, i_m\}$$

- множество финансовых активов.

Индекс $u \in \mathcal{U}$ обозначает инвестора, индекс $i \in \mathcal{I}$ - актив. Временная метка обозначается через t . В практической части пользователи идентифицируются полем `customerID`, а активы - полем `ISIN`.

2.2 Транзакции и матрица взаимодействий

Исходные данные о поведении инвесторов отображены в датасете с транзакциями. Для пары (u, i) может быть известно количество покупок актива i пользователем u . Обозначим его через

$$c_{ui}.$$

На основе транзакций строится бинарная матрица взаимодействий

$$R \in \{0, 1\}^{|\mathcal{U}| \times |\mathcal{I}|},$$

где

$$r_{ui} = \begin{cases} 1, & \text{если инвестор } u \text{ покупал актив } i, \\ 0, & \text{иначе.} \end{cases}$$

Матрица R описывает неявную обратную связь. В данных нет явных оценок активов, поэтому факт покупки считается за положительное взаимодействие.

Для части моделей дополнительно используется интенсивность взаимодействия c_{ui} . Например, она может преобразовываться в вес взаимодействия:

$$w_{ui} = \log(1 + c_{ui}).$$

2.3 Обучающая, валидационная и тестовая выборки

Так как транзакции имеют временную структуру, данные разделяются по времени:

$$\mathcal{D}_{train}, \quad \mathcal{D}_{valid}, \quad \mathcal{D}_{test}.$$

На обучающей выборке строятся модели и признаки. Валидационная выборка используется для подбора гиперпараметров и весов гибридной модели. Тестовая выборка используется только для финального сравнения качества моделей.

Для каждого разбиения строятся матрицы:

$$R^{train}, \quad R^{valid}, \quad R^{test}.$$

2.4 Положительные и отрицательные примеры

Для инвестора u множество купленных активов обозначается как

$$\mathcal{I}_u^+ = \{i \in \mathcal{I} : r_{ui} = 1\}.$$

Множество активов без наблюдаемого взаимодействия:

$$\mathcal{I}_u^- = \mathcal{I} \setminus \mathcal{I}_u^+.$$

Важно, что $\mathcal{I}_u^-$ не обязательно означает, что актив пользователю не нравится. Это означает только то, что в данных не было покупки этого актива.

В моделях NCF и Content-aware LGBM используются отрицательные примеры. Они формируются с помощью negative sampling: для каждого положительного взаимодействия случайно выбирается несколько активов из $\mathcal{I}_u^-$.

2.5 Признаки пользователей и активов

Для пользователя u задается вектор признаков

$$x_u \in \mathbb{R}^{d_u}.$$

В работе используются, например, следующие признаки инвесторов:

- тип клиента;
- риск-профиль;
- инвестиционная способность;
- число купленных активов;
- общее число взаимодействий;
- среднее число взаимодействий на актив;
- средняя и максимальная популярность купленных активов.

Для актива i задается вектор признаков

$$y_i \in \mathbb{R}^{d_i}.$$

К признакам активов относятся:

- категория и подкатегория актива;
- рынок обращения;
- сектор, индустрия и страна;
- валюта;
- доходности за разные периоды;
- волатильность;
- максимальная просадка;
- ценовые и риск-доходные показатели.

Эти признаки используются в модели Content-aware LGBM и при объяснении рекомендаций.

2.6 Скоринг и Тор-К рекомендации

Рекомендательная модель строит функцию

$$s_m(u, i),$$

где $s_m(u, i)$ - скор модели m для пары инвестор-актив.

Для каждого инвестора формируется ранжированный список активов. Итоговый список рекомендаций длины K задается как

$$TopK_m(u) = \operatorname{topK}_{i \in \mathcal{I}} s_m(u, i).$$

В основной оценке используется $K = 10$, то есть рассматриваются рекомендации формата Тор-10.

В работе допускается повторная рекомендация уже купленных активов. Это соответствует инвестиционной логике: инвестор может не только покупать новый инструмент, но и докупать актив, который уже есть в его истории.

2.7 Рассматриваемые модели

В работе сравниваются несколько групп рекомендательных моделей.

Popularity - неперсонализированная модель, которая рекомендует наиболее популярные активы из обучающей выборки.

User-kNN - user-based коллаборативная фильтрация. Рекомендации строятся на основе активов, популярных среди похожих инвесторов.

Item-kNN - item-based коллаборативная фильтрация. Рекомендации строятся на основе сходства активов по истории взаимодействий.

SVD - модель матричной факторизации, в которой пользователи и активы представляются латентными векторами.

SVD++ - расширение SVD, дополнительно учитывающее неявные взаимодействия пользователя.

NMF - неотрицательная матричная факторизация. В этой модели латентные факторы пользователей и активов ограничены неотрицательностью.

WMF-ALS - взвешенная матричная факторизация для implicit feedback. Модель обучается алгоритмом alternating least squares и учитывает интенсивность взаимодействий.

BPR - модель персонализированного ранжирования. Она обучается так, чтобы купленные активы получали более высокий скор, чем случайно выбранные некупленные активы.

NCF - нейронная коллаборативная фильтрация. Модель использует эмбединги пользователей и активов, после чего скор пары (u, i) вычисляется нейронной сетью.

Content-aware LGBM - модель на основе градиентного бустинга, использующая признаки инвестора x_u , признаки актива y_i и обучающиеся метки покупки.

Hybrid Rank Fusion - гибридная модель, объединяющая ранжированные списки нескольких базовых моделей.

2.8 Латентные представления

В моделях матричной факторизации каждому инвестору и активу сопоставляются латентные векторы:

$$p_u \in \mathbb{R}^k, \quad q_i \in \mathbb{R}^k,$$

где k - размерность латентного пространства.

Оценка релевантности пары (u, i) может задаваться скалярным произведением:

$$\hat{r}_{ui} = p_u^\top q_i.$$

В NCF латентные представления также используются, но взаимодействие между ними задается не только скалярным произведением, а обучаемой нейронной сетью.

2.9 Гибридная модель

Гибридная модель объединяет рекомендации нескольких базовых алгоритмов. Пусть $rank_m(u, i)$ - позиция актива i в списке рекомендаций модели m для пользователя u , а w_m - вес этой модели.

Итоговый скор гибрида задается как

$$S(u, i) = \sum_{m \in \mathcal{M}} \frac{w_m}{rank_m(u, i)}.$$

Если актив отсутствует в списке кандидатов модели m , вклад этой модели считается равным нулю.

Веса моделей подбираются на валидационной выборке. В практической части в гибриде используются рекомендации User-kNN, NMF и Content-aware LGBM. Для расширения множества кандидатов базовые модели сначала формируют Top-50 списки, после чего гибридная модель строит итоговый Top-10 список.

2.10 Доходность и ROI

Для оценки финансового результата рекомендаций используется доходность актива. Пусть P_{i,t_0} - цена актива i в начале периода, а P_{i,t_1} - цена в конце периода. Тогда доходность актива равна

$$ROI_i = \frac{P_{i,t_1} - P_{i,t_0}}{P_{i,t_0}}.$$

Для списка рекомендаций $TopK(u)$ показатель $ROI@K$ считается как средняя доходность рекомендованных активов:

$$ROI@K(u) = \frac{1}{K} \sum_{i \in TopK(u)} ROI_i.$$

Итоговое значение $ROI@K$ по модели получается усреднением по пользователям.

2.11 Метрики качества рекомендаций

Качество рекомендаций оценивается с помощью ranking-метрик.

Precision@K показывает, какая доля рекомендованных активов действительно встретила в будущих покупках пользователя:

$$Precision@K(u) = \frac{|TopK(u) \cap \mathcal{I}_u^+|}{K}.$$

Recall@K показывает, какую долю будущих покупок пользователя удалось по-

крыть рекомендациями:

$$Recall@K(u) = \frac{|TopK(u) \cap \mathcal{I}_u^+|}{|\mathcal{I}_u^+|}.$$

nDCG@K учитывает не только факт попадания актива в список, но и его позицию:

$$DCG@K(u) = \sum_{j=1}^K \frac{rel_j}{\log_2(j+1)},$$

где $rel_j = 1$, если актив на позиции j является релевантным, и $rel_j = 0$ иначе.

Нормированная метрика:

$$nDCG@K(u) = \frac{DCG@K(u)}{IDCG@K(u)}.$$

В практической части используются метрики Precision@10, Recall@10, nDCG@10 и ROI@10.

2.12 Основные сокращения

В работе используются следующие сокращения:

- CF - Collaborative Filtering;
- kNN - k-Nearest Neighbors;
- SVD - Singular Value Decomposition;
- SVD++ - расширенная модель SVD с учетом implicit feedback;
- NMF - Non-negative Matrix Factorization;
- WMF - Weighted Matrix Factorization;
- ALS - Alternating Least Squares;
- BPR - Bayesian Personalized Ranking;
- NCF - Neural Collaborative Filtering;
- LGBM - Light Gradient Boosting Machine;
- ROI - Return on Investment;
- Top-K - список из K наиболее релевантных рекомендаций;
- FAR-Trans - Financial Asset Recommendation Transactions dataset.

3 Теоретическая часть (методы рекомендательных систем)

В этом разделе описаны методы, которые используются в практической части работы. Каждый алгоритм строит скор $s_m(u, i)$ для пары инвестор-актив. На основе этих скоров для каждого инвестора формируется ранжированный список рекомендаций.

3.1 Popularity

Модель Popularity используется как неперсонализированная базовая линия. Скор актива определяется количеством инвесторов, которые покупали этот актив в обучающей выборке:

$$s_{pop}(i) = \sum_{u \in \mathcal{U}} \mathbb{I}(r_{ui}^{train} = 1).$$

Итоговый список рекомендаций для любого пользователя строится по убыванию $s_{pop}(i)$:

$$TopK_{pop}(u) = \arg \top K_{i \in \mathcal{I}} s_{pop}(i).$$

Модель не использует индивидуальные признаки инвестора и отражает только общую популярность активов.

3.2 User-based kNN

User-based kNN строит рекомендации на основе поведения похожих инвесторов. Каждый пользователь представляется строкой матрицы взаимодействий R_u . Сходство между инвесторами u и v вычисляется с помощью косинусной меры:

$$sim(u, v) = \frac{R_u R_v^\top}{\|R_u\| \|R_v\|}.$$

Пусть $\mathcal{N}_k(u)$ - множество k ближайших пользователей к инвестору u . Тогда скор актива i задается как сумма взаимодействий похожих пользователей с этим активом:

$$s_{user}(u, i) = \sum_{v \in \mathcal{N}_k(u)} sim(u, v) r_{vi}.$$

Актив получает высокий скор, если его покупали инвесторы, близкие к пользователю u по истории покупок.

3.3 Item-based kNN

Item-based kNN строит рекомендации на основе сходства активов. Каждый актив представляется столбцом матрицы взаимодействий R_i . Сходство между активами i и j

задается формулой:

$$\text{sim}(i, j) = \frac{R_i^\top R_j}{\|R_i\| \|R_j\|}.$$

Для пользователя u скор кандидата i вычисляется через сходство с активами, которые пользователь уже покупал:

$$s_{item}(u, i) = \sum_{j \in \mathcal{I}_u^+} \text{sim}(i, j).$$

Модель рекомендует активы, похожие на уже купленные пользователем инструменты.

3.4 SVD

SVD относится к методам матричной факторизации. Идея метода состоит в том, чтобы представить пользователей и активы в общем латентном пространстве размерности k :

$$p_u \in \mathbb{R}^k, \quad q_i \in \mathbb{R}^k.$$

Скор пары пользователь-актив определяется скалярным произведением:

$$s_{svd}(u, i) = p_u^\top q_i.$$

Параметры модели подбираются так, чтобы восстановить наблюдаемые взаимодействия:

$$\mathcal{L}_{svd} = \sum_{(u,i) \in \mathcal{D}_{train}} (r_{ui} - p_u^\top q_i)^2 + \lambda (\|p_u\|^2 + \|q_i\|^2).$$

Латентные векторы позволяют описывать скрытые факторы инвестиционного поведения, которые не наблюдаются напрямую в исходных данных.

3.5 SVD++

SVD++ расширяет базовую матричную факторизацию за счет учета неявных взаимодействий пользователя. Пусть $N(u)$ - множество активов, с которыми пользователь взаимодействовал в обучающей выборке. Тогда пользовательское представление имеет вид:

$$\tilde{p}_u = p_u + |N(u)|^{-1/2} \sum_{j \in N(u)} y_j,$$

где y_j - латентный вектор актива j , отражающий вклад неявной обратной связи.

Скор пары задается формулой:

$$s_{svd++}(u, i) = \mu + b_u + b_i + q_i^\top \tilde{p}_u.$$

Здесь μ - общий средний уровень взаимодействия, b_u - смещение пользователя,

b_i - смещение актива.

В отличие от обычной SVD, эта модель использует не только индивидуальный латентный вектор пользователя, но и всю его историю взаимодействий.

3.6 NMF

NMF также представляет матрицу взаимодействий через произведение пользовательских и объектных факторов:

$$R \approx PQ^\top.$$

Главное ограничение модели - неотрицательность латентных факторов:

$$P \geq 0, \quad Q \geq 0.$$

Для пары (u, i) скор задается как

$$s_{nmf}(u, i) = p_u^\top q_i, \quad p_u \geq 0, \quad q_i \geq 0.$$

Функция потерь имеет вид:

$$\mathcal{L}_{nmf} = \sum_{(u,i) \in \mathcal{D}_{train}} (r_{ui} - p_u^\top q_i)^2, \quad P, Q \geq 0.$$

Неотрицательность факторов делает модель более интерпретируемой: итоговый скор складывается из неотрицательных вкладов скрытых компонент.

3.7 WMF-ALS

WMF-ALS предназначена для работы с неявной обратной связью. Для каждой пары (u, i) задается бинарное предпочтение:

$$p_{ui} = \mathbb{I}(c_{ui} > 0),$$

где c_{ui} - интенсивность взаимодействия пользователя u с активом i .

Дополнительно вводится вес уверенности:

$$\alpha_{ui} = 1 + \alpha c_{ui}.$$

Если взаимодействие наблюдалось часто, модель получает больший вес ошибки для этой пары. Оптимизационная задача имеет вид:

$$\mathcal{L}_{wmf} = \sum_{u \in \mathcal{U}} \sum_{i \in \mathcal{I}} \alpha_{ui} (p_{ui} - p_u^\top q_i)^2 + \lambda \left(\sum_u \|p_u\|^2 + \sum_i \|q_i\|^2 \right).$$

Модель обучается методом ALS. При фиксированных факторах активов Q оптимизируются пользовательские факторы P , затем при фиксированных P оптимизируются факторы активов Q .

3.8 BPR

BPR решает задачу персонализированного ранжирования. Для каждого пользователя рассматривается тройка (u, i, j) , где $i \in \mathcal{I}_u^+$ - положительный актив, а $j \in \mathcal{I}_u^-$ - ненаблюдаемый актив.

Модель должна выполнять условие:

$$s(u, i) > s(u, j).$$

Вероятность правильного порядка задается через сигмоидную функцию:

$$P(i \succ_u j) = \sigma(s(u, i) - s(u, j)),$$

где

$$\sigma(x) = \frac{1}{1 + e^{-x}}.$$

Функция потерь:

$$\mathcal{L}_{bpr} = - \sum_{(u, i, j)} \ln \sigma(s(u, i) - s(u, j)) + \lambda \|\Theta\|^2.$$

BPR оптимизирует не точность восстановления матрицы, а порядок активов в рекомендациях. Поэтому метод хорошо согласуется с задачей формирования Тор-К списка.

3.9 NCF

NCF заменяет скалярное произведение латентных факторов обучаемой нейронной сетью. Пользователь и актив сначала переводятся в эмбединги:

$$e_u = E_U(u), \quad e_i = E_I(i).$$

Затем эмбединги объединяются:

$$h_{ui}^{(0)} = [e_u, e_i].$$

Далее применяется многослойная нейронная сеть:

$$h_{ui}^{(l)} = \phi(W_l h_{ui}^{(l-1)} + b_l),$$

где ϕ - функция активации.

Итоговый скор:

$$s_{ncf}(u, i) = w^\top h_{ui}^{(L)} + b.$$

Вероятность взаимодействия:

$$\hat{y}_{ui} = \sigma(s_{ncf}(u, i)).$$

Для бинарной постановки используется функция потерь:

$$\mathcal{L}_{ncf} = - \sum_{(u, i)} [y_{ui} \log \hat{y}_{ui} + (1 - y_{ui}) \log(1 - \hat{y}_{ui})].$$

Положительные примеры соответствуют покупкам, а отрицательные формируются с помощью negative sampling.

3.10 Content-aware LGBM

Content-aware LGBM использует не только историю взаимодействий, но и признаки инвесторов и активов. Для пары (u, i) строится вектор признаков:

$$z_{ui} = [x_u, y_i, g(u, i)],$$

где x_u - признаки пользователя, y_i - признаки актива, $g(u, i)$ - дополнительные признаки пары.

Модель оценивает вероятность покупки:

$$\hat{y}_{ui} = F(z_{ui}),$$

где F - ансамбль решающих деревьев градиентного бустинга.

Обучение проводится по бинарной логистической функции потерь:

$$\mathcal{L}_{lgbm} = - \sum_{(u, i)} [y_{ui} \log \hat{y}_{ui} + (1 - y_{ui}) \log(1 - \hat{y}_{ui})].$$

Положительные объекты задаются наблюдаемыми покупками. Отрицательные примеры выбираются из множества активов, с которыми пользователь не взаимодействовал.

Преимущество этой модели состоит в том, что она может учитывать риск-профиль инвестора, категорию актива, рыночные признаки и показатели доходности.

3.11 Hybrid Rank Fusion

Гибридная модель объединяет рекомендации нескольких базовых алгоритмов. В работе используется ранговая агрегация. Пусть $rank_m(u, i)$ - позиция актива i в списке

рекомендаций модели m , а w_m - вес этой модели.

Итоговый скор гибрида:

$$S(u, i) = \sum_{m \in \mathcal{M}} \frac{w_m}{rank_m(u, i)}.$$

Если актив отсутствует в списке кандидатов модели m , его вклад считается равным нулю:

$$\frac{w_m}{rank_m(u, i)} = 0.$$

Итоговый список рекомендаций:

$$TopK_{hybrid}(u) = \arg \max_{i \in \mathcal{I}} S(u, i).$$

В практической части гибрид объединяет три модели:

$$\mathcal{M} = \{User-kNN, NMF, Content-aware LGBM\}.$$

Веса моделей подбираются на валидационной выборке:

$$(w_1^*, \dots, w_M^*) = \arg \max_{w_1, \dots, w_M} nDCG@10_{valid}.$$

Ранговая агрегация используется потому, что скоры разных моделей имеют разный масштаб. В отличие от усреднения исходных предсказаний, rank fusion сравнивает только позиции активов в списках рекомендаций.

4 Практическая часть

4.1 Описание набора данных FAR-Trans

В практической части работы используется набор данных FAR-Trans (Financial Asset Recommendation - Transactions), который используется для исследования рекомендательных систем в подборе финансовых активов. Датасет содержит информацию о транзакциях инвесторов, характеристиках пользователей, признаках финансовых инструментов и динамике цен активов.

В работе используются следующие таблицы:

- `transactions.csv` - данные о транзакциях инвесторов;
- `customer_information.csv` - информация об инвесторах;
- `asset_information.csv` - информация о финансовых активах;
- `close_prices.csv` - цены закрытия активов;
- `limit_prices.csv` - информация о ценовых границах и доходности;
- `markets.csv` - информация о рынках обращения активов.

Таблица транзакций содержит 388048 записей за период с 2 января 2018 года по 30 ноября 2022 года. В данных представлено 29090 инвесторов и 320 активов, по которым фактически совершались сделки. Всего в исходной таблице транзакций содержится 228913 покупок и 159135 продаж.

В таблице `customer_information.csv` содержится информация о 32468 записях и 29090 уникальных инвесторах. Для инвесторов доступны категориальные признаки: тип клиента, риск-профиль и инвестиционная емкость. В таблице `asset_information.csv` содержатся сведения о 806 уникальных финансовых инструментах, включая категорию актива, подкатегорию, рынок обращения, сектор и индустрию.

В этой работе задача рассматривается как задача рекомендаций на основе неявной обратной связи. Явные оценки активов пользователями отсутствуют, поэтому положительным взаимодействием считается факт покупки актива инвестором.

4.2 Предобработка данных и формирование матрицы взаимодействий

На первом этапе из таблицы транзакций были выделены только операции покупки. Продажи не использовались как положительные взаимодействия, поскольку продажа может отражать разные действия инвестора: фиксацию прибыли, снижение риска, ребалансировку портфеля или закрытие позиции.

После фильтрации покупок данные агрегировались до пар инвестор-актив. Для каждой пары (u, i) считалось количество покупок:

$$c_{ui} = \sum_{a \in \mathcal{D}} \mathbb{I}(\text{customerID}_a = u, \text{ISIN}_a = i, \text{transactionType}_a = \text{Buy}).$$

На основе агрегированной таблицы строилась бинарная матрица взаимодействий:

$$r_{ui} = \begin{cases} 1, & c_{ui} > 0, \\ 0, & c_{ui} = 0. \end{cases}$$

После агрегации было получено 89884 уникальных пар инвестор-актив. Для повышения устойчивости моделей и снижения влияния крайне редких наблюдений использовалась фильтрация по активности пользователей и популярности активов. В итоговый набор включались инвесторы, купившие не менее трех различных активов в обучающем периоде, и активы, купленные не менее чем тремя инвесторами:

$$|\mathcal{I}_u^+| \geq 3, \quad |\mathcal{U}_i^+| \geq 3.$$

После фильтрации итоговая матрица взаимодействий имеет размер:

$$7349 \times 250.$$

Число ненулевых элементов в обучающей матрице равно:

$$nnz(R^{\text{train}}) = 51478.$$

Разреженность обучающей матрицы составляет:

$$\text{sparsity} = 1 - \frac{51478}{7349 \cdot 250} \approx 97.20\%.$$

Высокая разреженность является базовой особенностью задачи рекомендации финансовых активов: большинство инвесторов взаимодействует только с небольшой долей доступных инструментов

4.3 Разведочный анализ данных

Для анализа структуры данных были рассмотрены распределения числа активов на инвестора, числа инвесторов на актив и числа повторных покупок для пары инвестор-актив. Поскольку эти распределения имеют выраженный правый хвост для визуализации используется логарифмическое преобразование $\log(1 + x)$.

На рисунке 1 представлено распределение числа активов на одного инвестора. Видно, что большая часть инвесторов покупает небольшое количество активов, тогда

как небольшая группа пользователей имеет более широкую историю взаимодействий. Такая структура приводит к высокой разреженности матрицы взаимодействий.




Рис. 1: Распределение логарифма числа активов на одного инвестора

На рисунке 2 показано распределение числа инвесторов на один актив. В данных присутствуют как массовые активы, покупавшиеся большим числом инвесторов, так и менее распространенные инструменты. Это важно для оценки качества моделей: популярные активы проще рекомендовать, тогда как редкие активы требуют более точного учета индивидуальных предпочтений.




Рис. 2: Распределение логарифма числа инвесторов на один актив

На рисунке 3 представлено распределение числа покупок актива одним инвестором. Большинство пар инвестор-актив имеет одно наблюдаемое взаимодействие, однако

для части пар встречаются повторные покупки. Поэтому в некоторых моделях используется не только бинарный факт покупки, но и интенсивность взаимодействия c_{ui} .




Рис. 3: Распределение логарифма числа покупок для пары инвестор-актив

Полученные распределения показывают, что данные обладают двумя важными свойствами: высокой разреженностью и неоднородной популярностью активов. Поэтому в эксперименте сравниваются как простые модели популярности, так и персонализированные методы, учитывающие историю взаимодействий пользователей.

4.4 Разбиение данных по времени

Для оценки качества моделей используется временное разбиение данных. Реализован такой подход, поскольку в инвестиционной задаче модель должна обучаться только на прошлых данных и оцениваться на будущих взаимодействиях. Случайное разбиение в постановке решаемой задачи привело бы к утечке информации из будущего, потому что в тест могли бы попасть данные за период более ранний, чем в трейн.

Транзакции были разделены на три части:

$$\mathcal{D}_{train} : t < 2021-10-01,$$

$$\mathcal{D}_{valid} : 2021-10-01 \leq t < 2022-04-01,$$

$$\mathcal{D}_{test} : t \geq 2022-04-01.$$

Размеры выборок по числу транзакций покупки составляют:

$$|\mathcal{D}_{train}| = 172419, \quad |\mathcal{D}_{valid}| = 30345, \quad |\mathcal{D}_{test}| = 26149.$$

После фильтрации пользователей и активов для каждого периода построены

бинарные матрицы одинакового размера:

$$R^{train}, R^{valid}, R^{test} \in \{0, 1\}^{7349 \times 250}.$$

Число положительных взаимодействий в матрицах:

$$nnz(R^{train}) = 51478, \quad nnz(R^{valid}) = 10295, \quad nnz(R^{test}) = 8261.$$

Обучающая выборка используется для построения моделей и признаков. Валидационная выборка используется для подбора гиперпараметров и весов гибридной модели. Тестовая выборка используется только для финального сравнения качества.

4.5 Формирование признаков пользователей и активов

Для контентной модели и интерпретации рекомендаций построены признаки пользователей и активов. Все признаки формировались на основе информации, доступной к концу обучающего периода, чтобы избежать утечки данных из валидационной и тестовой выборок.

Для инвесторов использовались признаки из таблицы `customer_information.csv`:

- `customerType` - тип клиента;
- `riskLevel` - риск-профиль;
- `investmentCapacity` - инвестиционная емкость.

Дополнительно на основе обучающих транзакций были рассчитаны поведенческие признаки:

- `user_n_assets_train` - число уникальных активов, купленных пользователем;
- `user_total_interactions_train` - общее число покупок;
- `user_avg_interactions_per_asset_train` - среднее число покупок на актив;
- `user_avg_asset_popularity_train` - средняя популярность купленных активов;
- `user_max_asset_popularity_train` - максимальная популярность купленного актива.

Также были добавлены бинарные признаки:

- `is_predicted_profile` - является ли риск-профиль предсказанным;
- `is_predicted_capacity` - является ли инвестиционная емкость предсказанной;
- `has_questionnaire` - есть ли у пользователя заполненная анкета.

Итоговая таблица признаков пользователей содержит 7349 строк и 12 столбцов. Для активов использовались базовые признаки:

- `assetCategory` - категория актива;
- `assetSubCategory` - подкатегория актива;
- `marketID` - рынок обращения;
- `marketClass` - класс рынка;
- `quoteType` - тип инструмента;
- `currency` - валюта;
- `sector_final`, `industry_final`, `country_final` - сектор, индустрия и страна.

На основе цен закрытия были рассчитаны рыночные признаки:

- `return_30d`, `return_90d`, `return_180d` - доходности за разные горизонты;
- `volatility_30d`, `volatility_90d` - волатильность;
- `max_drawdown_train` - максимальная просадка на обучающем периоде;
- `last_price_train` - последняя доступная цена на обучающем периоде;
- `sharpe_like_90d_train` - риск-доходный показатель;
- `positive_return_share_30d`, `positive_return_share_90d` - доля дней с положительной доходностью;
- `downside_volatility_30d`, `downside_volatility_90d` - волатильность отрицательных доходностей.

Итоговая таблица признаков активов содержит 250 строк и 37 столбцов. Эти признаки используются в модели Content-aware LGBM и при построении объяснений рекомендаций.

4.6 Экспериментальная методология

В эксперименте сравниваются одиннадцать моделей: Popularity, User-kNN, Item-kNN, SVD, SVD++, NMF, WMF-ALS, BPR, NCF, Content-aware LGBM и Hybrid Rank Fusion. Для каждой модели строится список из 10 рекомендаций для каждого инвестора:

$$TopK(u), \quad K = 10.$$

Оценка качества проводится на тестовой выборке. Релевантными считаются активы, которые пользователь купил в тестовом периоде. В отличие от товарных рекомендаций или рекомендаций фильмов ранее купленные активы не исключаются из кандидатов. Для инвестиционной задачи имеем: пользователь может не только покупать новый инструмент, но и докупать актив, который уже был в его истории.

Модель Popularity строится только по обучающей выборке. Для каждого актива считается число инвесторов, купивших его в train-периоде:

$$s_{pop}(i) = \sum_{u \in \mathcal{U}} \mathbb{I}(r_{ui}^{train} = 1).$$

После этого всем пользователям рекомендуется один и тот же список наиболее популярных активов.

User-kNN и Item-kNN обучаются на бинарной матрице R^{train} . Для User-kNN подбирается число похожих инвесторов, для Item-kNN - число похожих активов. В обеих моделях используется косинусное сходство. Эти модели не используют признаки пользователей и активов, а опираются только на структуру матрицы взаимодействий.

Для SVD, SVD++ и NMF использовалась библиотека **Surprise**. Так как эти модели работают с числовым значением взаимодействия, количество покупок пары инвестор-актив преобразовывалось в псевдо-рейтинг:

$$rating_{ui} = \log(1 + c_{ui}).$$

Это позволяет учитывать повторные покупки, но не дает слишком большой вес пользователям, которые много раз покупали один и тот же актив.

WMF-ALS и BPR реализованы с помощью библиотеки **implicit**. Для WMF-ALS использовалась разреженная матрица взаимодействий с confidence-масштабированием через параметр α . Логарифмический псевдо-рейтинг для этой модели не строился. BPR обучался на бинарной матрице взаимодействий и использовал стандартную для библиотеки процедуру формирования пар для ранжирования.

Для NCF был отдельно собран датасет из положительных и отрицательных пар. Положительные пары соответствуют покупкам в обучающей выборке. Для них использовался вес

$$w_{ui} = \log(1 + c_{ui}).$$

Отрицательные пары формировались с помощью *negative sampling* из активов, которые пользователь не покупал. Затем NCF обучалась как бинарная модель, предсказывающая вероятность взаимодействия пользователя с активом.

Content-aware LGBM обучался по аналогичной схеме на положительных и отрицательных парах. Для положительных наблюдений также использовался вес

$$w_{ui} = \log(1 + c_{ui}).$$

Главное отличие этой модели в том, что объект обучения описывается и идентификаторами пользователя и актива, и набором признаков: характеристиками инвестора, характеристиками актива и поведенческими признаками, рассчитанными на train-периоде.

Гиперпараметры подбирались на валидационной выборке. Для kNN-моделей варьировалось число соседей, для моделей факторизации - размерность латентного пространства, регуляризация и число итераций. Для NCF подбирались параметры обучения, а для Content-aware LGBM - параметры градиентного бустинга. После выбора настроек итоговое качество фиксировалось на тестовой выборке.

Гибридная модель строится по рангам скоров. Это важно, потому что значения скоров у разных алгоритмов находятся в разных масштабах и напрямую несопоставимы. Сначала каждая базовая модель формирует список из 50 кандидатов, затем для каждого актива считается общий скор:

$$S(u, i) = \sum_{m \in \mathcal{M}} \frac{w_m}{rank_m(u, i)}.$$

Если актив не попал в список кандидатов модели m , вклад этой модели считается равным нулю. В итоговый гибрид были включены три модели:

$$\mathcal{M} = \{User-kNN, NMF, Content-aware LGBM\}.$$

Веса подбирались на валидационной выборке по метрике nDCG@10. Лучшее сочетание оказалось следующим:

$$w_{User-kNN} = 0.8, \quad w_{NMF} = 0.2, \quad w_{Content-aware LGBM} = 0.$$

Поэтому финальный гибрид по сути объединяет только User-kNN и NMF. User-kNN дает основной вклад, а NMF добавляет факторную структуру взаимодействий. Content-aware LGBM не вошел в итоговый скор, так как на валидационной выборке его добавление не улучшило nDCG@10. При этом модель сохраняется в сравнении как отдельный контентный подход.

Качество рекомендаций оценивается с помощью Precision@10, Recall@10 и nDCG@10. Дополнительно рассчитывается ROI@10, который отражает среднюю доходность рекомендованных активов в тестовом периоде

4.7 Результаты экспериментов

Итоговые значения метрик на тестовой выборке представлены на рисунке 4. Тепловая карта позволяет сравнить модели одновременно по качеству ранжирования и по финансовому результату.




Рис. 4: Сравнение качества моделей на тестовой выборке

По ranking-метрикам лучшие результаты показывают User-kNN и Hybrid Rank Fusion. User-kNN достигает Precision@10, равного 0.191, Recall@10, равного 0.646, и nDCG@10, равного 0.482. Гибридная модель показывает сопоставимое качество: Precision@10 равен 0.191, Recall@10 равен 0.643, а nDCG@10 равен 0.485.

Для дополнительного анализа финансового результата модели сравнивались с рыночной доходностью за тестовый период. Результаты представлены в таблице 2.

Таблица 2: Сравнение ROI моделей с рыночной доходностью

Модель	ROI модели, %	ROI рынка, %	Разница, п.п.
Popularity	2.39	-6.37	8.76
User-kNN	-2.00	-6.37	4.37
Item-kNN	-2.27	-6.37	4.09
SVD	-1.71	-6.37	4.66
SVD++	-2.24	-6.37	4.13
NMF	2.08	-6.37	8.45
WMF-ALS	-3.63	-6.37	2.74
BPR	-3.78	-6.37	2.59
NCF	0.95	-6.37	7.31
Content-aware LGBM	-0.04	-6.37	6.33
Hybrid Rank Fusion	-1.05	-6.37	5.32

Из таблицы видно, что все модели показывают ROI@10 выше рыночной доходности, равной -6.37% . Наибольшую разницу с рынком дают Popularity и NMF: 8.76 и

8.45 процентного пункта соответственно. При этом эти модели не являются лучшими по ranking-метрикам, что показывает различие между задачей предсказания будущих покупок и задачей выбора наиболее доходных активов.

4.8 Анализ результатов

Результаты показывают, что модели основанные на истории взаимодействий пользователей, лучше всего справляются с задачей предсказания будущих покупок. User-kNN дает лучшие значения Precision@10 и Recall@10. Это говорит о том, что поведение похожих инвесторов в датасете это сильный источник информации для формирования рекомендаций.

Hybrid Rank Fusion показывает лучшее значение nDCG@10. В отличие от Precision@10 и Recall@10, эта метрика учитывает не только сам факт попадания релевантного актива в список, но и его позицию. Поэтому результат гибридной модели означает, что нужные активы чаще оказываются ближе к началу рекомендаций. Улучшенее nDCG@10 достигается за счет объединения ранжирований User-kNN и NMF. Первая модель хорошо улавливает поведенческое сходство между инвесторами, вторая добавляет факторную структуру взаимодействий. При этом вклад Content-aware LGBM в итоговом гибриде оказался равен нулю, поскольку на валидационной выборке добавление этой модели не улучшало качество ранжирования.

Item-kNN уступает User-kNN по всем ranking-метрикам. Скорее всего причина в том, что сходство между активами, построенное только по совместным покупкам, оказывается менее устойчивым при высокой разреженности матрицы. У многих инструментов число покупателей невелико, из-за этого оценки сходства между активами могут получаться довольно шумными.

SVD, SVD++ и NMF показывают средние результаты по ranking-метрикам. Эти модели выделяют латентные факторы, но сама задача восстановления матрицы не полностью совпадает с задачей построения Top-10 рекомендаций. Это особенно заметно для implicit feedback, где отсутствие покупки не означает отрицательное отношение пользователя к активу. При этом NMF показывает высокий ROI@10. Возможно так происходит потому, что неотрицательные факторы выделяют более устойчивые группы активов и не так сильно подстраиваются под отдельные шумные взаимодействия. Поэтому по финансовому результату модель оказывается лучше, чем по метрикам предсказания будущих покупок.

WMF-ALS и BPR учитывают специфику неявной обратной связи, но в данном эксперименте не превосходят User-kNN и Hybrid Rank Fusion. Для BPR ограничением может быть чувствительность к negative sampling: итоговое качество зависит от того, какие ненаблюдаемые активы выбираются в качестве отрицательных примеров. Для WMF-ALS результат сильно зависит от параметра уверенности и размерности латентного пространства.

NCF показывает конкурентный, но не лучший результат. В целом это ожидаемо:

нейросетевые модели часто требуют более плотных данных и большого числа наблюдений на пользователя. В данной задаче матрица инвестор-актив остается сильно разреженной, поэтому более простые модели оказываются не хуже нейросетевого подхода.

Content-aware LGBM использует признаки пользователей и активов, но по ranking-метрикам уступает User-kNN. Это показывает, что в данном эксперименте история взаимодействий оказалась более информативной, чем доступные табличные признаки. Тем не менее контентная модель полезна для интерпретации, потому что ее рекомендации можно связать с конкретными характеристиками инвестора и финансового инструмента.

Прокомментирую расхождение между ranking-метриками и ROI@10. Модель может хорошо предсказывать будущие покупки инвесторов, но при этом рекомендовать активы с отрицательной доходностью. В нашем случае тестовое разбиение пришлось на период спада экономики, что видно по среднему показателю ROI по всем активам - он отрицательный и заметно ниже чем ROI рекомендаций моделей, которые используются в работе.

Поэтому в задаче инвестиционных рекомендаций недостаточно смотреть только на Precision@10, Recall@10 и nDCG@10. Эти метрики показывают, насколько хорошо модель воспроизводит поведение инвесторов, но не отвечают на вопрос о финансовой привлекательности рекомендаций. Для этого используется ROI@10.

4.9 Объяснение рекомендаций

Для инвестиционных рекомендаций важно объяснить, почему актив был рекомендован пользователю. В работе рассматриваются разные типы объяснений в зависимости от используемого алгоритма.

Таблица 3: Подходы к объяснению рекомендаций

Модель	Логика объяснения
Popularity	Актив рекомендован, потому что он часто покупался инвесторами в обучающей выборке.
User-kNN	Актив рекомендован, потому что его покупали инвесторы с похожей историей покупок.
Item-kNN	Актив похож на инструменты, которые пользователь покупал ранее.
SVD, SVD++, NMF, WMF-ALS, BPR	Рекомендация связана с близостью пользователя и актива в латентном пространстве. Для объяснения можно использовать ближайшие активы или наиболее похожие ранее купленные инструменты.
NCF	Рекомендация основана на нелинейном взаимодействии эмбедингов пользователя и актива. Для объяснения можно использовать похожие активы и признаки самого инструмента.
Content-aware LGBM	Рекомендация объясняется через признаки пользователя и актива: риск-профиль, категорию инструмента, доходность, волатильность, сектор и другие характеристики.
Hybrid Rank Fusion	Актив попал в итоговый список, потому что получил высокие позиции в одной или нескольких базовых моделях.

В практической реализации для гибридной модели можно разложить итоговый скор рекомендации на вклады отдельных моделей:

$$S(u, i) = \frac{w_{User-kNN}}{rank_{User-kNN}(u, i)} + \frac{w_{NMF}}{rank_{NMF}(u, i)} + \frac{w_{LGBM}}{rank_{LGBM}(u, i)}.$$

Так можно объяснить, какая модель сильнее всего повлияла на попадание актива в итоговый список. Например если актив имеет высокую позицию в User-kNN, рекомендацию можно объяснить поведением похожих инвесторов. Если актив высоко ранжируется NMF, объяснение связано с латентной факторной структурой. Если вклад Content-aware LGBM положителен, рекомендацию можно связать с признаками актива и пользователя.

Объяснение рекомендаций строится не единым способом для всех моделей, а зависит от природы алгоритма. Это особенно важно в финансовой сфере, где пользователю надо объяснять почему стоит купить тот или иной актив, иначе неквалифицированному инвестору будет сложно довериться прогнозам модели

4.10 Ограничения практической реализации

Проведенный эксперимент и ограничения.

Во-первых, в данных отсутствуют явные оценки активов пользователями. Факт покупки интерпретируется как положительное взаимодействие, однако покупка не все-

гда означает устойчивое предпочтение пользователя. Аналогично отсутствие покупки не означает, что актив пользователю не подходит. Во-вторых, данные содержат только исторические транзакции. В них нет информации о том, видел ли пользователь конкретный актив, рассматривал ли он его как вариант покупки и как бы он отреагировал на рекомендацию. Поэтому задача решается как offline-оценка по будущим покупкам, а не как полноценный онлайн-эксперимент. В-третьих, модели оцениваются на фиксированном временном разбиении. Такой подход учитывает хронологию данных, но не полностью отражает изменение предпочтений инвесторов и рыночных условий во времени. В-четвертых, ROI@10 рассчитывается на основе исторической доходности активов и не учитывает комиссии, налоги, ликвидность, ограничения по объему сделки и индивидуальные требования к риску портфеля. Поэтому ROI@10 следует рассматривать как дополнительный индикатор, а не как полноценную оценку инвестиционной эффективности стратегии. В-пятых, в работе не реализуются методы обучения с подкреплением. Для их применения требуется интерактивная среда, симулятор поведения инвесторов или данные о реакции пользователей на рекомендации. В FAR-Trans представлены только исторические транзакции, поэтому применение reinforcement learning выходит за рамки данной работы.

Несмотря на эти ограничения, проведенный эксперимент позволяет сравнить основные классы рекомендательных моделей на едином наборе данных и оценить, как различаются качество ранжирования и финансовый результат рекомендаций.

Заключение

Личный вклад. Основная часть работы была связана не только с запуском готовых моделей, а с построением полного пайплайна под задачу рекомендации финансовых активов. Сначала были загружены и изучены таблицы FAR-Trans: транзакции, информация об инвесторах, описание активов, цены закрытия, лимитные цены и данные о рынках. Дальше исходные данные нужно было привести к виду, с которым вообще могут работать рекомендательные алгоритмы. Из истории сделок были выделены покупки, так как именно они в работе считаются положительными взаимодействиями пользователя с активом. После этого транзакции агрегировались до пары `customerID-ISIN`: для каждой такой пары считалось число покупок. На этой основе была построена бинарная матрица взаимодействий инвестор-актив

Следующий шаг - фильтрация. В исходных данных много инвесторов с одной покупкой и активов с очень малым числом покупателей. Если оставить всё как есть, персонализированные модели будут обучаться на слишком шумной и разреженной матрице. Поэтому были отфильтрованы пользователи и активы с недостаточным числом наблюдений. После фильтрации итоговая матрица взаимодействий имела размер 7349×250 , число ненулевых элементов в обучающей матрице составило 51478, а разреженность оказалась около 97.20%.

Отдельно был проведен разведочный анализ данных. Были построены распределения числа активов на инвестора, числа инвесторов на актив и числа повторных покупок для пары инвестор-актив. Эти графики показывают, почему задача сложная: большинство инвесторов покупает мало инструментов, популярность активов распределена очень неравномерно. Для оценки моделей использовалось временное разбиение. Это принципиальный момент для финансовых данных: нельзя случайно перемешать транзакции и обучаться на информации из будущего. Поэтому модели обучались на более раннем периоде, параметры подбирались на валидационном периоде, а финальное качество считалось на тестовой выборке. После подготовки матрицы были построены признаки пользователей и активов. Для пользователей использовались как исходные признаки из анкеты, например тип клиента, риск-профиль и инвестиционная емкость, так и признаки, рассчитанные по обучающей истории: число купленных активов, общее число взаимодействий, среднее число покупок на актив, средняя и максимальная популярность купленных инструментов. Для активов были собраны категориальные признаки: категория, подкатегория, рынок, валюта, сектор, индустрия и страна. Кроме того, по ценовым данным FAR-Trans были рассчитаны доходности за разные периоды, волатильность, максимальная просадка, последняя доступная цена на обучающем периоде и дополнительные риск-доходные характеристики.

Была также предпринята попытка обогатить данные через `yfinance`. Идея состояла в том, чтобы сопоставить активы из FAR-Trans с рыночными тикерами и добавить внешние финансовые признаки. На практике этот шаг оказался ограниченно применимым: для части инструментов не удалось найти тикеры или получить полные ценовые

ряды. Поэтому `yfinance` не стал основой финальной модели, но сама попытка была полезной. Она показала, что в финансовых рекомендациях качество сопоставления инструментов между источниками - это отдельная нетривиальная задача.

После этого были реализованы и сравнены одиннадцать моделей: Popularity, User-kNN, Item-kNN, SVD, SVD++, NMF, WMF-ALS, BPR, NCF, Content-aware LGBM и Hybrid Rank Fusion. Для SVD, SVD++ и NMF использовалась библиотека `Surprise`; для WMF-ALS и BPR - библиотека `implicit`. Для NCF и Content-aware LGBM отдельно формировались положительные и отрицательные пары, так как в исходных данных нет явных негативных оценок. Так же удалось собрать гибридную модель. Вместо прямого усреднения скоров была реализована ранговая агрегация: базовые модели сначала формировали списки кандидатов, а затем итоговый скор актива считался через его позиции в этих списках. Такой подход удобен, потому что скоры разных моделей имеют разный масштаб. Веса гибрида подбирались на валидационной выборке по `nDCG@10`.

В конце были рассчитаны `Precision@10`, `Recall@10`, `nDCG@10` и `ROI@10`, построена итоговая тепловая карта качества моделей и проведено сравнение доходности рекомендаций с рыночным ориентиром. Кроме численного сравнения, был отдельно разобран смысл результатов: почему User-kNN оказался сильным по `ranking`-метрикам, почему гибрид улучшил `nDCG@10` и почему лучшие модели по будущим покупкам не обязательно дают лучший `ROI@10`.

Выводы. По итогам работы удалось собрать полный сценарий решения задачи: от исходных транзакций до сравнения рекомендательных моделей и анализа финансового результата. Работа не сводилась к одной модели или одной метрике. Главная идея была в том, чтобы посмотреть, как разные подходы ведут себя на одной финансовой задаче.

Первый вывод связан с данными. FAR-Trans в целом подходит для исследования финансовых рекомендаций, потому что содержит транзакции, признаки инвесторов, характеристики активов и ценовую динамику. При этом датасет сразу показывает основную сложность: матрица взаимодействий получается очень разреженной. А так же сам датасет не такой уж и большой - для более успешного результата на скоринге для большинства моделей нужно значительно больше данных. Большая часть инвесторов покупает мало активов. Значительная часть активов имеет ограниченное число покупателей. Поэтому без фильтрации и аккуратной подготовки данных модели работали бы менее устойчиво.

Второй вывод касается постановки задачи. Для финансовых активов нельзя спокойно использовать случайное разбиение данных. Если перемешать транзакции, модель может получить информацию из будущего. Поэтому в работе использовался `time-aware split`: обучение на раннем периоде, подбор параметров на валидации и финальная проверка на тесте.

Третий вывод связан с базовыми моделями. По `Precision@10` и `Recall@10` лучше всего показала себя User-kNN. Это означает, что поведение похожих инвесторов ока-

залось очень сильным источником информации. Если группы пользователей покупали похожие активы раньше, то эта информация действительно помогает предсказывать их будущие покупки. Item-kNN оказался слабее User-kNN. Скорее всего, причина в том, что сходство между активами сложнее надежно оценить только по совместным покупкам. Для части инструментов наблюдений мало, поэтому оценки похожести активов становятся шумными. Модели матричной факторизации дали более смешанные результаты. SVD, SVD++ и NMF позволяют выделять скрытые факторы взаимодействий, но восстановление матрицы не всегда совпадает с задачей построения Top-10 рекомендаций. Особенно это заметно в данных с implicit feedback: отсутствие покупки не означает, что актив пользователю не подходит. При этом NMF показала высокий ROI@10. Модель может быть не лучшей по предсказанию будущих покупок, но при этом рекомендовать финансово более удачные активы. BPR и WMF-ALS учитывают специфику неявной обратной связи, но в данном эксперименте не превзошли User-kNN и гибридную модель. Для BPR результат мог зависеть от negative sampling, а для WMF-ALS - от параметра уверенности и размерности латентного пространства. NCF показала конкурентное, но не лучшее качество. Оно и понятно - нейросетевые модели обычно требуют больше данных и более плотной истории взаимодействий. В этой задаче матрица инвестор-актив остается сильно разреженной, поэтому более простые методы не проигрывают нейросетевому подходу. Content-aware LGBM оказался полезен для сравнения, но по ranking-метрикам уступил User-kNN. Значит, в этой постановке история взаимодействий оказалась информативнее доступных табличных признаков. При этом контентная модель важна для объяснения рекомендаций, потому что ее решения можно связать с характеристиками пользователя и актива. Гибридная модель показала лучший результат по nDCG@10. Это значит, что релевантные активы чаще оказывались выше в списке рекомендаций. Лучшие веса гибрида составили 0.8 для User-kNN, 0.2 для NMF и 0 для Content-aware LGBM. Получается, что итоговый гибрид в основном опирается на поведенческое сходство пользователей, но немного дополняет его факторной структурой NMF. Добавление LGBM в итоговый скор на валидационной выборке не улучшило nDCG@10.

Главный содержательный вывод работы состоит в том, что качество предсказания будущих покупок и финансовая доходность рекомендаций - это разные вещи. Модель может хорошо воспроизводить поведение инвесторов, но это поведение не обязано быть финансово оптимальным. Инвесторы могут покупать популярные активы, следовать трендам или просто покупать то, что посоветовал друг. Поэтому основная гипотеза подтвердилась частично. Гибридная модель улучшила качество ранжирования по nDCG@10, но не стала лучшей по ROI@10. Значит, одного объединения поведенческих моделей недостаточно, если цель - максимизация финансового результата. Для этого нужно отдельно учитывать доходность, риск, ликвидность и портфельные ограничения.

Ограничения исследования. Главное ограничение связано с тем, что в дан-

ных нет явных оценок активов. Пользователь не ставит активу рейтинг и не сообщает, насколько он ему подходит. Поэтому покупка используется как положительный сигнал. Покупка может быть случайной, краткосрочной или вызванной внешними обстоятельствами. Отсутствие покупки тоже нельзя считать настоящим отрицательным сигналом. Инвестор мог не купить актив не потому, что он ему не подходит, а потому что он не видел этот инструмент, не имел свободных средств или просто не рассматривал его в конкретный момент. Поэтому *negative sampling* в NCF, BPR и Content-aware LGBM создает технически необходимые отрицательные примеры, но эти примеры не являются настоящими отказами пользователя.

Еще одно ограничение - *offline-оценка*. Модели сравниваются по историческим будущим покупкам, но в данных нет информации о том, какие рекомендации пользователь видел бы в реальности. Нет показов, кликов, отказов, времени просмотра и реакции на конкретную рекомендацию.

Финансовая часть оценки тоже упрощена. ROI@10 считается по историческим ценам и помогает сравнить модели между собой, но это не полноценная инвестиционная стратегия. В расчете не учитываются комиссии, налоги, спреды, ликвидность, ограничения на объем сделки и индивидуальные ограничения пользователя. Также ROI@10 не учитывает структуру портфеля. Список из десяти активов - это еще не оптимально собранный портфель.

В работе не использовались макроэкономические переменные: процентные ставки, инфляция, валютные курсы, рыночные индексы и общая волатильность. Такие факторы могут сильно влиять и на поведение инвесторов, и на доходность активов. Часть этой информации косвенно отражается в ценах, но явно в модели она не задана, поскольку этих данных нет в датасете, а специфический Греческий рынок требует скрупулезной работы над ручным сбором этих данных.

Есть и ограничение, связанное с внешним обогащением данных. Попытка использовать *yfinance* показала, что сопоставление инструментов FAR-Trans с рыночными тикерами не всегда получается надежным. Из-за этого внешние данные не были использованы как основа финального пайплайна.

Методы обучения с подкреплением в работе не реализованы. Для них нужны данные о последовательном взаимодействии пользователя с рекомендациями или хотя бы симулятор такой среды. В FAR-Trans есть исторические транзакции, но нет данных о показах рекомендаций и реакции пользователей на них.

Приложения результатов. Полученные результаты можно рассматривать как основу для прототипа рекомендательной системы в брокерском приложении, инвестиционной платформе или финтех-сервисе. Такая система могла бы помогать пользователю ориентироваться среди большого числа финансовых инструментов и быстрее находить активы, похожие на его прошлые покупки или на выбор похожих инвесторов.

Для бизнеса такой подход полезен не только как механизм рекомендаций. Он также помогает анализировать клиентское поведение: какие группы инвесторов поку-

пают похожие инструменты, какие активы становятся массовыми, а какие интересны только узким сегментам пользователей.

Это может использоваться для персонализации интерфейса, сегментации клиентов и улучшения инвестиционных сервисов.

Отдельно важен результат про расхождение ranking-метрик и ROI@10. Он показывает, что хорошее предсказание будущих покупок еще не гарантирует лучший финансовый результат. Для практического применения это принципиально: в инвестиционных рекомендациях нельзя оптимизировать только попадание в будущие действия пользователя.

Нужно одновременно смотреть на релевантность, доходность, риск и объяснимость.

Предложенный гибридный подход можно использовать как понятный способ объединять несколько источников информации. User-kNN отражает поведение похожих инвесторов, NMF добавляет скрытую факторную структуру, а контентная модель может учитывать признаки пользователя и актива. Даже если в финальном гибриде вес LGBM оказался нулевым, сама идея остается полезной: на других данных или при другой целевой метрике признаки активов могут дать больший вклад.

Блок объяснения рекомендаций тоже имеет прикладное значение. В финансовой сфере рекомендация не должна выглядеть как черный ящик. Пользователю важно понимать, почему ему предлагается конкретный инструмент: из-за поведения похожих инвесторов, сходства с уже купленными активами, риск-профиля или характеристик самого актива.

Направления для дальнейших исследований. Первое направление развития - более явный учет финансовой стороны задачи. Дальше можно изменить итоговый скор так, чтобы он учитывал не только релевантность для пользователя, но и доходность, риск, ликвидность и диверсификацию. Второе направление - переход от списка активов к портфелю. Сейчас модель формирует Топ-10 рекомендаций, но не решает задачу распределения долей между инструментами. Для инвестиционной задачи это важное расширение: пользователь покупает не просто набор активов, а портфель с определенным уровнем риска и ожидаемой доходности. Третье направление связано с временной динамикой. В текущей работе предпочтения пользователя описываются в основном через агрегированную историю покупок. Но порядок сделок и давность взаимодействий тоже могут быть важны. В дальнейшем можно использовать последовательные модели, временные признаки, рекуррентные архитектуры или трансформеры.

Можно попробовать более качественное внешнее обогащение данных. Попытка использовать `yfinance` показала, что это не всегда делается автоматически и без ошибок. В будущей работе можно отдельно заняться сопоставлением ISIN, тикеров и торговых площадок, чтобы надежно добавлять внешние рыночные признаки: индексы, мультипликаторы, дивидендную доходность, ликвидность и другие показатели. Не стоит забывать и про объяснимость рекомендаций. Для Content-aware LGBM можно строить

объяснения через вклад признаков, для kNN - через похожих инвесторов или активы, для гибрида - через вклад каждой базовой модели в итоговый скор.

Еще один возможный вариант - онлайн-оценка. Offline-метрики полезны на этапе исследования, но они не заменяют проверки в реальной среде. Для более сильной оценки нужны данные о показах рекомендаций, кликах, покупках после рекомендации и отказах. А в следствии этого перспективным направлением остается и обучение с подкреплением. Если появятся данные о последовательной реакции пользователей или будет построен симулятор инвестиционного поведения, можно будет оптимизировать краткосрочное попадание в покупку и долгосрочную полезность рекомендаций.

Список литературы

- [1] Afsar, M. M., Crump, T., & Far, B. (2022). Reinforcement learning based recommender systems: A survey. *ACM Computing Surveys*, 55(7), 1-38. <https://arxiv.org/pdf/2101.06286>
- [2] Burke, R. (2002). Hybrid recommender systems: Survey and experiments. *User Modeling and User-Adapted Interaction*, 12(4). https://pzs.dstu.dp.ua/DataMining/recom/bibl/Hybrid_Recommender_Systems_Survey_and_Experiments.pdf
- [3] Chung, M., Lee, J., Lee, Y., & Kim, W. C. (2025). Mean variance efficient collaborative filtering for stock recommendations. In *Proceedings of the 6th ACM International Conference on AI in Finance (ICAIF '25)*. <https://arxiv.org/pdf/2306.06590>
- [4] He, X., Liao, L., Zhang, H., Nie, L., Hu, X., & Chua, T.-S. (2017). Neural collaborative filtering. In *Proceedings of the 26th International Conference on World Wide Web* (pp. 173-182). <https://arxiv.org/pdf/1708.05031>
- [5] Hu, Y., Koren, Y., & Volinsky, C. (2008). Collaborative filtering for implicit feedback datasets. In *Proceedings of the 8th IEEE International Conference on Data Mining*. <https://yifanhu.net/PUB/cf.pdf>
- [6] Koren, Y. (2008). Factorization meets the neighborhood: A multifaceted collaborative filtering model. In *Proceedings of the 14th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. https://people.engr.tamu.edu/huangrh/Spring16/papers_course/matrix_factorization.pdf
- [7] Koren, Y., Bell, R., & Volinsky, C. (2009). Matrix factorization techniques for recommender systems. *Computer*, 42(8). [https://datajobs.com/data-science-repo/Recommender-Systems-\[Netflix\].pdf](https://datajobs.com/data-science-repo/Recommender-Systems-[Netflix].pdf)
- [8] Lee, D. D., & Seung, H. S. (1999). Learning the parts of objects by non-negative matrix factorization. *Nature*, 401(6755). <https://www.cs.columbia.edu/~blei/fogm/2020F/readings/LeeSeung1999.pdf>
- [9] Markowitz, H. (1952). Portfolio selection. *The Journal of Finance*, 7(1), 77-91. https://www.researchgate.net/publication/228051028_Portfolio_Selection
- [10] Pazzani, M. J., & Billsus, D. (2007). Content-based recommendation systems. In *The Adaptive Web: Methods and Strategies of Web Personalization* (pp. 325-341). Springer. <https://masters.donntu.ru/2024/fist/safonov/library/content-based-recommendation-systems.pdf>
- [11] Rendle, S., Freudenthaler, C., Gantner, Z., & Schmidt-Thieme, L. (2009). BPR: Bayesian personalized ranking from implicit feedback. In *Proceedings of the 25th*

- Conference on Uncertainty in Artificial Intelligence* (pp. 452-461). <https://arxiv.org/pdf/1205.2618>
- [12] Resnick, P., Iacovou, N., Suchak, M., Bergstrom, P., & Riedl, J. (1994). GroupLens: An open architecture for collaborative filtering of netnews. In *Proceedings of the 1994 ACM Conference on Computer Supported Cooperative Work* (pp. 175-186). <https://dl.acm.org/doi/epdf/10.1145/192844.192905>
 - [13] Sanz-Cruzado, J., Droukas, N., & McCreadie, R. (2024). FAR-Trans: An investment dataset for financial asset recommendation. *arXiv preprint arXiv:2407.08692*. <https://arxiv.org/pdf/2407.08692>
 - [14] Sarwar, B., Karypis, G., Konstan, J., & Riedl, J. (2001). Item-based collaborative filtering recommendation algorithms. In *Proceedings of the 10th International Conference on World Wide Web* (pp. 285-295). https://files.grouplens.org/papers/www10_sarwar.pdf
 - [15] Xue, H.-J., Dai, X.-Y., Zhang, J., Huang, S., & Chen, J. (2017). Deep matrix factorization models for recommender systems. In *Proceedings of the 26th International Joint Conference on Artificial Intelligence*. <https://www.ijcai.org/proceedings/2017/0447.pdf>
 - [16] Zhang, Y., & Chen, X. (2020). Explainable recommendation: A survey and new perspectives. *Foundations and Trends in Information Retrieval*, 14(1), 1-101. <https://arxiv.org/pdf/1804.11192>
 - [17] Zibriczky, D. (2016). Recommender Systems meet Finance: A literature review. In *Proceedings of the 2nd International Workshop on Personalization and Recommender Systems in Financial Services (FinRec 2016)* (pp. 3-10). https://www.researchgate.net/publication/304040294_Recommender_Systems_meet_Finance_A_literature_review
 - [18] Банк России. Снижение ставок подогревает интерес инвесторов к фондовому рынку. URL: <https://www.cbr.ru/press/event/?id=29564>
 - [19] Банк России. Рынок розничных инвестиций. URL: https://www.cbr.ru/analytics/finstab/retail_investment_market/
 - [20] Интерфакс. Объем размещенных цифровых финансовых активов в России в 2025 году вырос почти в три раза. URL: <https://www.interfax.ru/business/1077694>

Описание применения генеративной модели

При подготовке курсовой работы я использовал генеративную модель ChatGPT, доступную на сайте <https://chatgpt.com/>. ИИ применялся как вспомогательный инструмент для работы с текстом и оформлением. Модель использовалась в отдельных фрагментах работы. В основном это касалось обзора литературы и заключения. Формат использования можно описать как авторский текст с использованием сгенерированных материалов. Я писал код, проводил расчеты, строил таблицы и графики, а затем использовал модель, чтобы привести черновые формулировки и результаты к более понятному и связному виду. ChatGPT помогал сглаживать формулировки, убирать повторы, переводить поток мыслей по ноутбуку в аккуратный почти научный текст. Также модель использовалась для проверки соответствия текста итоговому коду, так как ноутбук получился достаточно большим, помогало не забыть важные шаги пайплайна. Отдельно ИИ применялся для технической помощи с L^AT_EX: исправления ошибок компиляции в Overleaf, проверки математических окружений, таблиц, рисунков и ссылок. Все численные результаты, значения метрик, размеры выборок и выводы проверялись мной по итоговому ноутбуку и исходным данным. Сгенерированные фрагменты текста редактировались вручную, неподтвержденные факты и неиспользованные в коде методы в работу не включались. Использование генеративной модели помогло, так как ускорило написание текста. При этом содержательная часть исследования и финальные выводы остались моей работой.